Аналитический отчет по курсовой работе

Прогноз для задачи Drug Discovery

Выполнил: Пагин Денис

Номер студенческого:M255621

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ 3
ДАННЫЕ И МЕТОДОЛОГИЯ 4
ИССЛЕДОВАТЕЛЬСКИЙ АНАЛИЗ ДАННЫХ (EDA) 5
РЕГРЕССИОННЫЕ МОДЕЛИ 7
КЛАССИФИКАЦИОННЫЕ МОДЕЛИ 10
СОВМЕСТНЫЙ АНАЛИЗ И ВЫВОДЫ: РЕГРЕССИЯ И КЛАССИФИКАЦИЯ 13
РЕКОМЕНДАЦИИ 14

ВВЕДЕНИЕ

Постановка задачи

Процесс разработки лекарственных препаратов включает множество этапов и требует значительных временных и финансовых ресурсов. Цель данной работы - применить методы машинного обучения для ускорения этапа первичного отбора перспективных химических соединений по их числовым дескрипторам.

В рамках проекта были поставлены 7 задач:

1) Регрессия: предсказание IC50.
2) Регрессия: предсказание CC50.
3) Регрессия: предсказание SI.
4) Классификация: IC50 выше медианы выборки.
5) Классификация: CC50 выше медианы выборки.
6) Классификация: SI выше медианы выборки.
7) Классификация: SI выше фиксированного порога 8.

Ключевая цель исследования - сравнить несколько алгоритмов, выбрать наиболее качественные решения по каждой задаче и интерпретировать полученные результаты с точки зрения прикладной полезности.

ДАННЫЕ И МЕТОДОЛОГИЯ

Исходные данные

В рамках настоящей работы были предоставлены конфиденциальные данные, содержащие информацию о 1000 химических соединениях, протестированных на противовирусную активность в отношении вируса гриппа.

Файл с данными: *data/Данные_для_курсовои_Классическое_МО.xlsx*

Каждое соединение в датасете описывается набором числовых признаков (молекулярных дескрипторов), а также тремя целевыми переменными, характеризующими его биологическую активность и безопасность:

- **IC50** — концентрация вещества, ингибирующая активность вируса на 50%;
- **CC50** — концентрация, вызывающая токсический эффект на 50% клеток;
- **SI** — селективный индекс (отношение CC50 к IC50), показывающий терапевтическое окно препарата.

Методология

Для каждой задачи выполнялся единый пул действий:

1) Подготовка данных и выделение целевого признака.
2) Масштабирование признаков (где это необходимо для конкретного алгоритма).
3) Обучение набора моделей с подбором гиперпараметров.
4) Сравнение моделей по релевантным метрикам качества.
5) Выбор лучшей модели по итоговым метрикам.

ИССЛЕДОВАТЕЛЬСКИЙ АНАЛИЗ ДАННЫХ (EDA)

Статистическая сводка этапов очистки

Этап	Наблюдение	Практический смысл
Исходный датасет	1001 наблюдение, 214 столбцов	Есть служебный столбец и 32 полных дубликата, которые не несут прогностической ценности
После очистки	969 наблюдений, 213 признаков	Потери умеренные, структура данных сохранена
Пропуски	Пропуски были, после медианного заполнения: 0	Каждое соединение важно, поэтому выбран не дроп строк, а импутация
Типы данных	Все признаки числовые (float/int)	Удобная база для классического ML без сложного кодирования
Целевые переменные	IC50, CC50, SI имеют правостороннюю асимметрию	Редкие экстремальные случаи сильно влияют на ошибку
Выбросы	Доля выбросов: IC50 = 14,2%, CC50 = 3,6%, SI = 12,4%	Для IC50 и SI нужна осторожная интерпретация метрик
Масштабы признаков	Признаки разношкальные	Для линейных моделей критично масштабирование
Корреляции	Выделены связанные с целями дескрипторы (например, MolWt, TPSA, qed)	Полезно для feature engineering и отбора признаков

Описательная статистика целевых переменных

Переменная	median	max	skew
IC50	45.34	4128.53	3.76
CC50	424.17	4538.98	2.00
SI	3.90	15620.60	17.73

Полученные значения указывают на выраженную правостороннюю асимметрию распределений, особенно для SI, где skew достигает 17.73. Это означает наличие небольшого числа экстремально больших значений, существенно отличающихся от основной массы наблюдений.

Выводы по EDA:

- выраженная асимметрия и наличие выбросов могут негативно влиять на качество регрессионных моделей, особенно при использовании метрик, чувствительных к большим ошибкам (например, RMSE). Это означает, что качество предсказаний может существенно различаться между «типичными» и экстремальными наблюдениями.
- высокая размерность признакового пространства (более 200 дескрипторов) при ограниченном числе наблюдений увеличивает риск переобучения и требует использования моделей, способных эффективно работать в таких условиях.
- потенциально сложные (в том числе нелинейные) зависимости между химическими дескрипторами и целевыми переменными делают целесообразным тестирование как простых (линейных), так и более гибких моделей.

В связи с этим в рамках дальнейшего анализа для каждой задачи будут рассмотрены несколько классов алгоритмов:

- линейные модели (LinearRegression, Ridge);
- ансамблевые методы (GradientBoosting, RandomForest);
- методы, способные строить нелинейные границы в задачах классификации (LogisticRegression, SVC).

РЕГРЕССИОННЫЕ МОДЕЛИ

Общие результаты

Задача	Лучшая модель	RMSE	MAE	R2
IC50	GradientBoosting	1.1607	0.9222	0.6349
CC50	RandomForest	1.0348	0.6971	0.5441
SI	GradientBoosting	1.2969	0.9487	0.2556

Результаты по IC50:

Файл: *02_regression_ic50.ipynb*

Модель	RMSE	MAE	R2	Статус
GradientBoosting	1.1607	0.9222	0.6349	Выбрана
RandomForest	1.1679	0.9120	0.6303	Отброшена
Ridge	1.4164	1.1173	0.4563	Отброшена
LinearRegression	1.4211	1.1988	0.4527	Отброшена

Результаты по CC50:

Файл: *03_regression_cc50.ipynb*

Модель	RMSE	MAE	R2	Статус
RandomForest	1.0348	0.6971	0.5441	Выбрана
GradientBoosting	1.1063	0.7789	0.4790	Отброшена
Ridge	1.1916	0.8809	0.3955	Отброшена
LinearRegression	1.2727	0.9476	0.3105	Отброшена

Результаты по SI:

Файл: *04_regression_si.ipynb*

Модель	RMSE	MAE	R2	Статус
GradientBoosting	1.2969	0.9487	0.2556	Выбрана
RandomForest	1.3467	0.9700	0.1973	Отброшена
LinearRegression	1.3685	1.0618	0.1711	Отброшена
Ridge	1.3803	1.0253	0.1568	Отброшена

IC50 (регрессия)

Лучшая модель: GradientBoosting

Метрики: $R^2 = 0.6349$, MAE = 0.9222, RMSE = 1.1607

Вывод: Модель объясняет значительную часть вариации IC50. Превышение RMSE над MAE указывает на наличие отдельных выбросов (подтверждено EDA). GradientBoosting выбран из-за устойчивости к нелинейностям, масштабам признаков и частично — к выбросам.

Практический смысл: Прогнозирование IC50 позволяет отбирать перспективные соединения, но модель требует доработки точности.

CC50 (регрессия)

Лучшая модель: RandomForest

Метрики: $R^2 = 0.5441$, MAE = 0.6971, RMSE = 1.0348

Вывод: Модель стабильна, ошибка равномерна, влияние выбросов незначительно. RandomForest выбран за счёт устойчивости к шуму, снижения дисперсии через бэггинг и лучшего обобщения на неоднородных данных.

Практический смысл: Прогноз CC50 надёжен в основной области значений и может использоваться для оценки безопасности соединений.

SI (регрессия)

Лучшая модель: GradientBoosting

Метрики: $R^2 = 0.2556$, MAE = 0.9487, RMSE = 1.2969

Вывод: Низкое качество объясняется природой SI (отношение CC50/IC50), накоплением ошибок и экстремальной асимметрией (skew $\approx$ 17.7). GradientBoosting справляется лучше других, но не компенсирует особенности распределения.

Практический смысл: Прогноз SI в непрерывном виде ненадёжен. Модель допустимо использовать только как вспомогательный ориентир, но не как финальный критерий отбора соединений.

Промежуточный вывод по блоку регрессии

Из полученных результатов становится понятно:

- модели для IC50 и CC50 целесообразно использовать для ранжирования и предварительного отбора соединений;

- регрессию SI в текущем виде использовать ограниченно, отдавая приоритет классификационным постановкам, где влияние выбросов ниже;

- дальнейшее улучшение качества требует дополнительной работы с признаками и трансформациями целевых переменных.

КЛАССИФИКАЦИОННЫЕ МОДЕЛИ

Общие результаты

Задача	Лучшая модель	Accuracy	Precision	Recall	F1	ROC-AUC
IC50 > median	RandomForest	0.7268	0.7200	0.7423	0.7310	0.8049
CC50 > median	RandomForest	0.7474	0.7553	0.7320	0.7435	0.8368
SI > median	SVC	0.6701	0.6988	0.5979	0.6444	0.7190
SI > 8	RandomForest	0.7165	0.6400	0.4638	0.5378	0.7428

Результаты по IC50 > median:

Файл: *05_classification_ic50_median.ipynb*

Модель	Accuracy	Precision	Recall	F1	ROC-AUC	Статус
RandomForest	0.7268	0.7200	0.7423	0.7310	0.8049	Выбрана
SVC	0.7113	0.6952	0.7526	0.7228	0.7908	Отброшена
LogisticRegression	0.7113	0.7113	0.7113	0.7113	0.7715	Отброшена
GradientBoosting	0.7062	0.7128	0.6907	0.7016	0.7947	Отброшена

Результаты по CC50 > median:

Файл: *06_classification_cc50_median.ipynb*

Модель	Accuracy	Precision	Recall	F1	ROC-AUC	Статус
RandomForest	0.7474	0.7553	0.7320	0.7435	0.8368	Выбрана
SVC	0.7320	0.7320	0.7320	0.7320	0.8101	Отброшена
GradientBoosting	0.7268	0.7115	0.7629	0.7363	0.8034	Отброшена
LogisticRegression	0.7062	0.6887	0.7526	0.7192	0.7813	Отброшена

Результаты по SI > median:

Файл: *07_classification_si_median.ipynb*

Модель	Accuracy	Precision	Recall	F1	ROC-AUC	Статус
SVC	0.6701	0.6988	0.5979	0.6444	0.7190	Выбрана
GradientBoosting	0.6959	0.7639	0.5670	0.6509	0.7032	Отброшена
RandomForest	0.6495	0.6790	0.5670	0.6180	0.6871	Отброшена
LogisticRegression	0.6186	0.6264	0.5876	0.6064	0.6540	Отброшена

Результаты по SI > 8:

Файл: *08_classification_si_8.ipynb*

Модель	Accuracy	Precision	Recall	F1	ROC-AUC	Статус
RandomForest	0.7165	0.6400	0.4638	0.5378	0.7428	Выбрана
GradientBoosting	0.7062	0.6111	0.4783	0.5366	0.7347	Отброшена
SVC	0.7423	0.7111	0.4638	0.5614	0.7225	Отброшена
LogisticRegression	0.7010	0.5873	0.5362	0.5606	0.6752	Отброшена

IC50 > медианы

Лучшая модель: RandomForest

Модель хорошо разделяет классы, Precision/Recall/F1 сбалансированы. RandomForest устойчив к шумным и слабоинформативным признакам.

Вывод: Классификатор пригоден как быстрый фильтр для отбора активных соединений на ранней стадии.

CC50 > медианы

Лучшая модель: RandomForest

Лучший результат среди всех классификаций. Модель одновременно держит высокие Precision и Recall.

Вывод: наиболее зрелый классификатор в проекте. Готов к использованию как основной экран токсикологического риска.

SI > медианы

Лучшая модель: SVC

Качество умеренное. SVC с RBF-ядром лучше деревьев находит сложную разделяющую поверхность.

Вывод: Модель — скорее подсказчик, чем надёжный классификатор. Требует улучшений.

SI > 8

Лучшая модель: RandomForest

Recall критически низкий: модель пропускает много перспективных соединений. В drug discovery это недопустимо.

Рекомендация: сместить фокус на увеличение Recall, даже ценой снижения Precision.

Вывод по блоку классификации

IC50 и CC50 показывают лучшее качество (ROC-AUC до 0.84) благодаря устойчивому распределению таргетов.

Медианный порог даёт сбалансированные классы и повышает интерпретируемость моделей.

SI > 8 — самая сложная задача: низкий Recall снижает практическую ценность.

Деревья и SVC превосходят линейные методы, что подтверждает наличие нелинейных зависимостей в данных.

СОВМЕСТНЫЙ АНАЛИЗ И ВЫВОДЫ: РЕГРЕССИЯ И КЛАССИФИКАЦИЯ

Ключевые наблюдения

- На таргетах IC50 и CC50 модели показывают стабильный и прикладно полезный уровень качества как в регрессии, так и в классификации.
- Таргет SI является наиболее сложным: низкий R2 в регрессии и умеренные метрики в классификации.
- Алгоритм RandomForest оказался наиболее универсальным и часто давал лучшие результаты в задачах бинарной классификации.
- Для непрерывного прогноза лучше проявили себя ансамбли бустинга и бэггинга (GradientBoosting и RandomForest), что согласуется с природой нелинейных зависимостей в химико-биологических данных.

Практические выводы для drug discovery

1. На этапе первичного фильтра кандидатов можно использовать модели классификации по IC50/CC50.
2. Регрессию IC50 и CC50 стоит использовать как ранжирующий механизм (приоритезация кандидатов для лабораторной валидации).
3. Для SI в текущем виде лучше опираться на комбинированную стратегию:
    a. классификация для грубого отбора,
    b. последующая экспертная и экспериментальная проверка.

РЕКОМЕНДАЦИИ

№	Рекомендация	Конкретные шаги
1	Усиление feature engineering	генерация взаимодействий признаков; отбор наиболее информативных дескрипторов; проверка нелинейных трансформаций
2	Улучшение валидации	использование повторной кросс-валидации; контроль стабильности метрик по фолдам
3	Оптимизация для задачи SI > 8	смещение фокуса на Recall / F-beta; настройка class_weight и порога решения